Parte 1

Aqui importaremos librerias

In [1]:
```
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib as clrs
import numpy as np
import seaborn as sns

from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, confusion_matrix, plot_confusion_matrix

from sklearn.tree import DecisionTreeRegressor
from sklearn.naive_bayes import GaussianNB

%matplotlib notebook
```

In [2]:
```
## Se agrega el DataFrame que se trabajará en la actividad
## Se le da el nombre de "df"
df = pd.read_csv('celulares.csv',sep=",")
## Se desprende que la cantidad de filas y columnas que tenemos en dicha DataFrame = df son 2200 rows y 22 colu
df=df.dropna()
## Mediante el comando df.dropna() se eliminaron todas las filas que contuvieran valores nulos del data frame,
## esto debido a que no se le puede atribuir un valor en especifico y sin ello, nosotros no podemos ver como va
## Por otro lado, por ejemplo, en caso de que los componentes que tienen valores NAN sean de gama baja o muy ba
## esto podria aumentar el presupuesto para los demas componentes, con lo cual, se dañaria el dataframe.
df
```

Out[2]:

	Unnamed: 0	battery_power	blue	clock_speed	dual_sim	fc	four_g	int_memory	m_dep	mobile_wt	...	px_height	px_width	ram
0	0	1663.0	1.0	2.5	1.0	13.0	1.0	27.0	0.3	169.0	...	831.0	1439.0	2084.0
1	1	1663.0	1.0	0.5	0.0	0.0	0.0	40.0	0.6	147.0	...	951.0	1545.0	1336.0
2	2	1323.0	1.0	2.5	1.0	10.0	1.0	28.0	0.2	131.0	...	162.0	619.0	1892.0
3	3	1099.0	0.0	0.5	0.0	13.0	1.0	61.0	0.3	146.0	...	393.0	1096.0	1699.0
4	4	1563.0	0.0	1.7	1.0	10.0	0.0	16.0	0.1	151.0	...	410.0	572.0	3922.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
2195	2195	1867.0	0.0	2.3	0.0	0.0	1.0	9.0	0.1	191.0	...	712.0	1442.0	990.0
2196	2196	541.0	1.0	2.3	0.0	4.0	0.0	51.0	0.4	200.0	...	1012.0	1226.0	403.0
2197	2197	1814.0	0.0	1.4	1.0	1.0	1.0	9.0	0.4	141.0	...	756.0	786.0	3556.0
2198	2198	1027.0	1.0	2.2	0.0	0.0	0.0	63.0	0.8	102.0	...	152.0	714.0	1732.0
2199	2199	987.0	1.0	1.9	0.0	4.0	1.0	52.0	0.5	83.0	...	419.0	736.0	2757.0

2000 rows × 22 columns

In [3]:
```
df[['battery_power','pc','px_width','ram','three_g','wifi','price_range']].groupby("price_range").describe()
```

Out[3]:

	battery_power								pc		...	three_g					
	count	mean	std	min	25%	50%	75%	max	count	mean	...	75%	max	count	mean	std	min
price_range																	
0.0	500.0	1116.902	410.801305	503.0	770.50	1066.0	1431.25	1994.0	500.0	9.574	...	1.0	1.0	500.0	0.496	0.500485	0.0
1.0	500.0	1228.868	438.614528	501.0	843.00	1206.0	1596.25	1996.0	500.0	9.924	...	1.0	1.0	500.0	0.504	0.500485	0.0
2.0	500.0	1228.320	452.863065	501.0	816.50	1219.5	1635.75	1998.0	500.0	10.018	...	1.0	1.0	500.0	0.504	0.500485	0.0
3.0	500.0	1379.984	414.992261	503.0	1034.75	1449.5	1733.50	1994.0	500.0	10.150	...	1.0	1.0	500.0	0.524	0.499924	0.0

4 rows × 48 columns

No influiran en la prediccion

- unnamed --> No se toma en cuenta debido a que no aporta ninguna diferencia al momento de clasificar y poder hacer la selección.
- Blue --> No se toma en cuenta debido a que los promedios generaban ciertas inconsistencias en cada rango de precio, es decir, el promedio de celulares con bluetooth en el rango de precio 1.0 es mas alto que el promedio de celulares con bluetooth en el rango de precio 2.0. Por otro lado, vemos que al menos el 25% de los celulares de todos los rangos de precios poseen bluetooth, por lo que el tener o no bluetooth no parece ser una metrica confiable para predecir el rango de precio.
- clock_speed --> No se tomará en cuenta, puesto que, las mayores velocidades de ejecución de tareas por parte del procesador, los tienen aquellos ubicados en el rango de precio 0.0. Por otro lado, podemos ver que el promedio es inconsistente, pues, no es descendente ni ascendente en cuanto al rango de precio.
- dual_sim --> No se tomara en cuenta debido a la inconsistencia que presentan los promedios en el rango de precios 1.0 y 2.0, esto, a causa de que hay mas celulares que poseen dual_sim en el rango de precio 1.0 que en el rango de precio 2.0.
- fc --> Esta caracteristica no sera tomada en cuenta debido a que el promedio no es consistente con la tendencia que presenta el precio. Ademas, tenemos que en el rango de precio 0.0, hay un celular con 19 megapixeles en la camara frontal, el cual, es un maximo global, pasando asi, a los celulares de mayor rango de precio.
- four_g --> Se eliminara debido a la falta de congruencia en los promedios (lo cual, se observa al pasar del rango de precio 1.0 al rango de precio 2.0).
- m_dep --> No sera tomado en cuenta debido a que derechamente es inconsistente con la tendencia de los rangos de precios. Probablemente esto sea debido a que los anchos de los celulares en su mayoria son los mismos.
- mobile_wt --> Tampoco sera tomado en cuenta, pues, el rango de precio 2.0 rompe con la tendencia general que habia en el peso de los dispositivos, por lo que, los datos dañarian la capacidad de prediccion.
- n_cores --> Estos no se tomaran en cuenta debido a que presentan una distribucion practicamente al azar, por lo que, solo dañarian la prediccion.
- px_height --> Muestra inconsistencia con la tendencia de los precios, por lo cual, no se toma en cuenta.
- sc_h --> No se tomara en cuenta, pues, segun parece, el alto de la pantalla disminuye a medida que aumenta el precio del celular desde el rango 0.0 al rango 2.0, sin embargo, vemos que los celulares del rango de precio 3.0 rompen con esta tendencia, por lo cual, podria conducir a errores.
- sc_w --> No sera tomado en cuenta debido a que presenta incongruencia en el rango de precio 1.0.
- talk_time --> No se tomara como caracteristica para predecir debido a que presenta una distribucion relativamente al azar.
- touch_screen --> No se tomara como caracteristica pues, no parece tener una tendencia general, por lo cual, no aportaria mucha informacion valiosa para la prediccion.

Dejar

- Battery_power --> Este dato se tomara en cuenta debido a que, el promedio parece tener cierta congruencia con los rangos de precios, es decir, a medida que aumenta el poder de la bateria, tiende a aumentar el precio del celular. Esto se puede ver reflejado en el promedio, en el 50% y en el 75% del describe.
- pc --> Este dato sera tomado en cuenta, pues, posee una distribucion uniforme y acorde a la tendencia que presentan los precios.
- px_width --> Se tomara en cuenta, pues, debido a que presenta cierta incongruencia con la tendencia de los precios, es minima, por lo cual, en general, aportara informacion valiosa para la prediccion.
- ram --> La ram es totalmente congruente con la tendencia de los precios, por lo cual, se utilizara como caracteristica para predecir los rangos de precios.
- three_g -->Este se utilizara como caracteristica para predecir los rangos de precios, debido a que a pesar de presentar cierta incongruencia en el rango de precio 3.0 , en general va acorde con la tendencia de estos.
- wifi -->A pesar de presentar un promedio similar en el rango de precio 1.0 y en el rango de precio 2.0, en general, presenta una tendencia al aumento junto a los rangos de precios.
- price_range --> sera el criterio en base al cual se hara la clasificacion.
- int_memory --> Este se dejara, pues, se usara como criterio base para la regresion.

In [4]:
```
seleccion_df=df[['battery_power','pc','px_width','int_memory','ram','three_g','wifi','price_range']]
seleccion_df
seleccion_dfint=df[['battery_power','pc','px_width','ram','three_g','wifi','int_memory']]
```

In [7]:
```
ax6 = sns.boxplot(x="price_range", y="battery_power", data=seleccion_df)
ax6 = sns.swarmplot(x="price_range", y="battery_power", data=seleccion_df, color=".25",size=3)
```

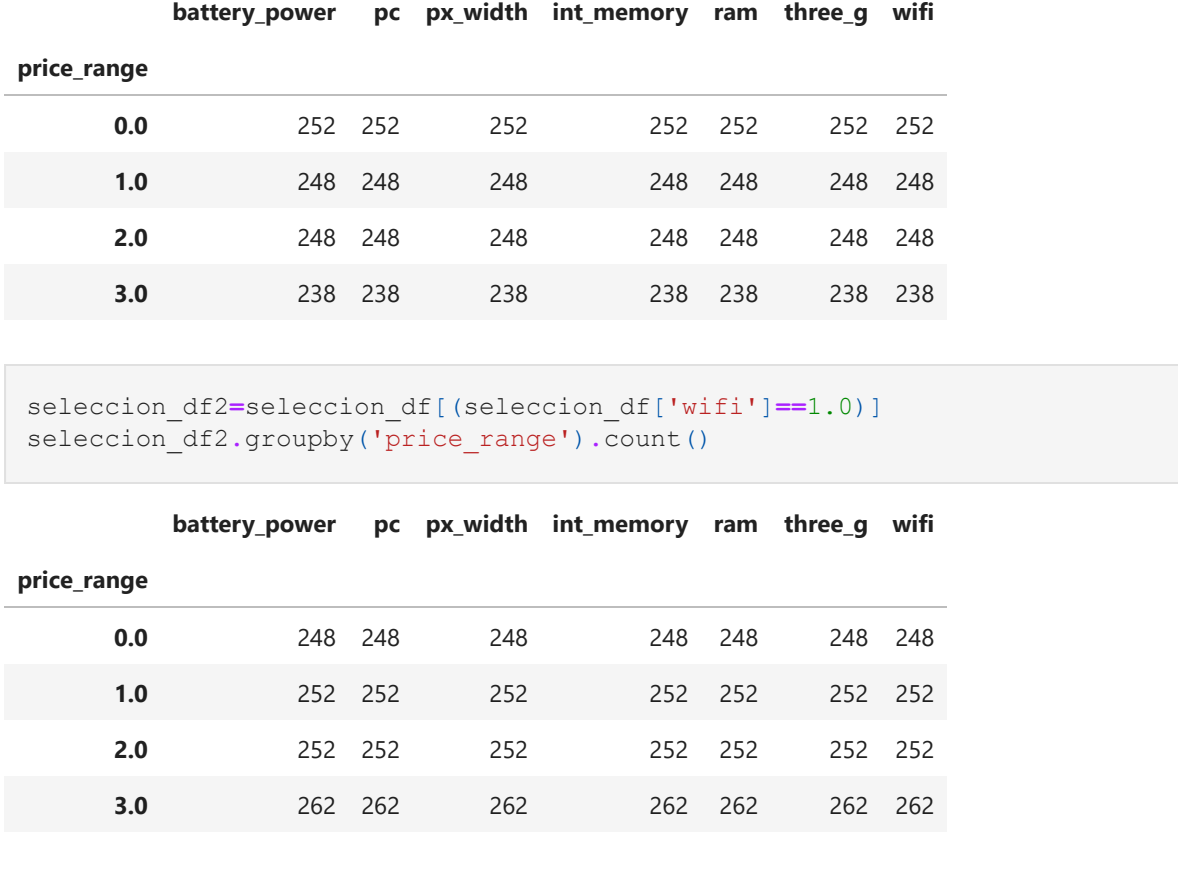

En este grafico se relaciona el poder de bateria con el rango de precio. Cada cajita tiene una linea, la cual es el promedio de poder de bateria en cada rango de precio, por lo tanto, podemos que ver que el promedio aproximado de poder de bateria en los rangos de precios 0.0, 1.0, 2.0 y 3.0, son 1050, 1200, 1210 y 1450, respectivamente. En consecuencia a los datos dados anteriormente, tenemos que hay una correlacion positiva entre ambas caracteristicas, es decir, a medida que aumenta el rango de precio, aumenta asi mismo el poder de bateria.

In [5]:
```
seleccion_df1=seleccion_df[(seleccion_df['wifi']==0.0)]
seleccion_df1.groupby('price_range').count()
```

Out[5]:

	battery_power	pc	px_width	int_memory	ram	three_g	wifi
price_range							
0.0	252	252	252	252	252	252	252
1.0	248	248	248	248	248	248	248
2.0	248	248	248	248	248	248	248
3.0	238	238	238	238	238	238	238

In [6]:
```
seleccion_df2=seleccion_df[(seleccion_df['wifi']==1.0)]
seleccion_df2.groupby('price_range').count()
```

Out[6]:

	battery_power	pc	px_width	int_memory	ram	three_g	wifi
price_range							
0.0	248	248	248	248	248	248	248
1.0	252	252	252	252	252	252	252
2.0	252	252	252	252	252	252	252
3.0	262	262	262	262	262	262	262

In [18]:
```
labels = ['0.0', '1.0', '2.0', '3.0'] #Ponemos los rangos de precios en las etiquetas del grafico, las cuales s
Si = [248, 252, 252, 262] #Se establecen los valores de celulares que tienen wifi
No= [252, 248, 248, 238] #Se establecen los valores de celulares que no tienen wifi

x = np.arange(len(labels))  # the label locations
width = 0.25  # the width of the bars

fig, ax = plt.subplots() #Hace posible que hayan dos barras para poder comparar el si y el no
rects1 = ax.bar(x - width/2, Si, width, label='Si') #Genera la barra que se utilizara para los que tienen wifi
rects2 = ax.bar(x + width/2, No, width, label='No') #Genera la barra que se utilizara para los que no tienen wi

# Add some text for labels, title and custom x-axis tick labels, etc.
ax.set_ylabel('Count') #Etiqueta eje y
ax.set_title('Celulares con wifi vs celulares sin wifi') #Titulo del grafico #
ax.set_xticks(x) #Cuadra eje x con las etiquetas
ax.set_xticklabels(labels) #Se ponen las etiquetas en el eje x
ax.legend() #Cartelito de si y no

ax.bar_label(rects1, padding=0) #Cantidad de celulares que tienen wifi
ax.bar_label(rects2, padding=0) #Cantidad de celulares que no tienen wifi


fig.tight_layout() #Cuadra el cartelito de acuerdo a la ubicacion del grafico

plt.show() #muestra el grafico
```

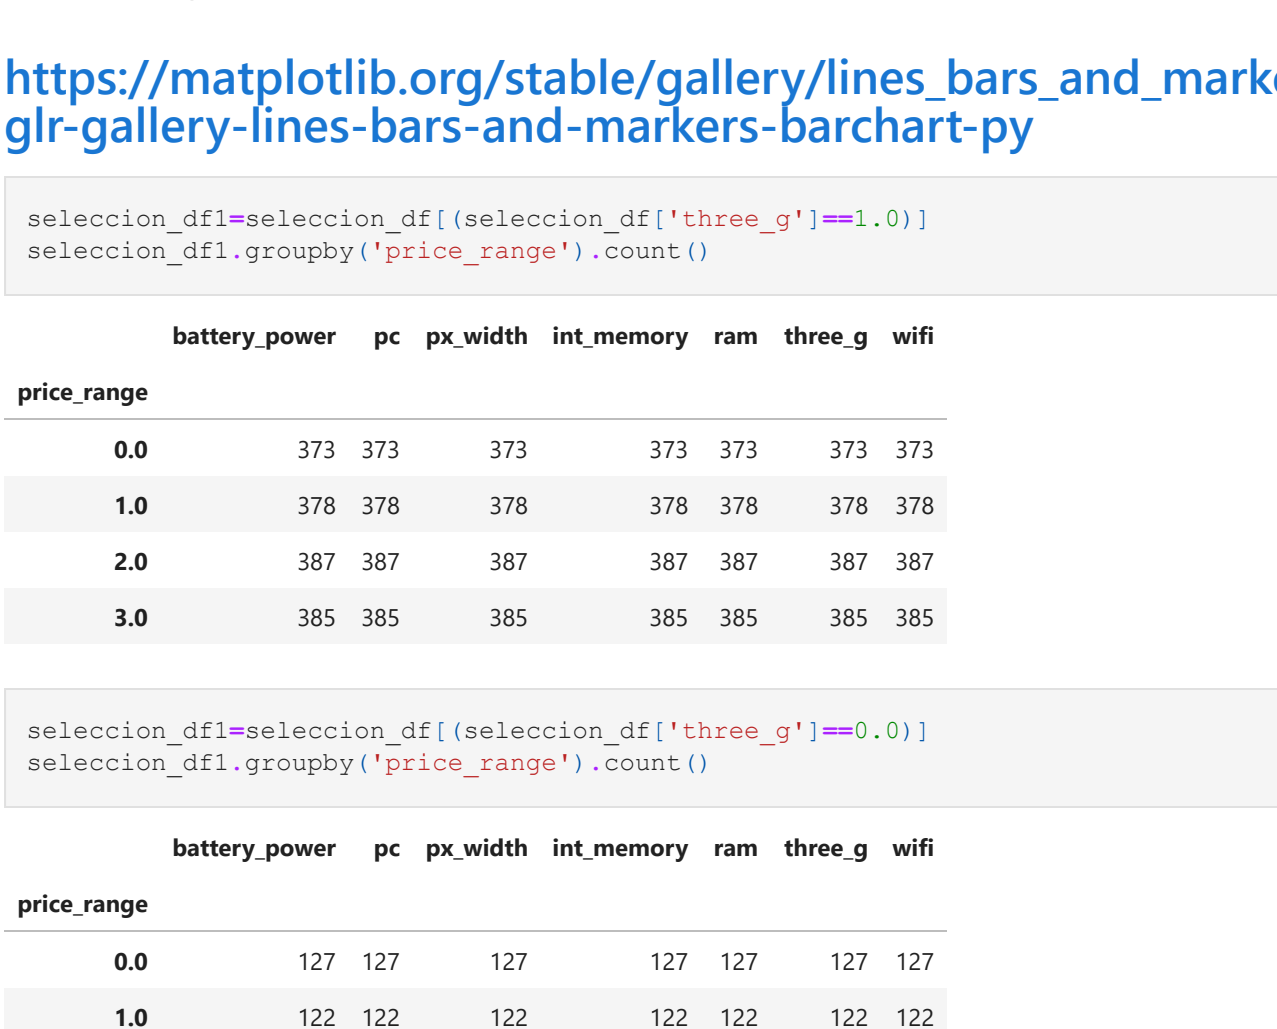

Este grafico nos muestra como se distribuyen la cantidad de celulares que si tienen wifi y los que no tienen wifi segun el rango de precio. Es decir, en los rangos de precio 0.0, 1.0, 2.0 y 3.0 hay 248, 252, 252 y 262 celulares que tienen wifi, respectivamente. Por otro lado, en los rangos de precio 0.0, 1.0, 2.0, 3.0 hay 252, 248, 248 y 238 celulares que no tienen wifi, respectivamente. Debido a lo anteriormente mencionado, podemos ver que la cantidad de celulares con wifi es congruente con los rangos de precios, pues, a medida que aumenta el rango de precio, tiende a aumentar la cantidad de celulares con wifi.

Idea de grafico extraida de

https://matplotlib.org/stable/gallery/lines_bars_and_markers/barchart.html#sph glr-gallery-lines-bars-and-markers-barchart-py

In [9]:
```
seleccion_df1=seleccion_df[(seleccion_df['three_g']==1.0)]
seleccion_df1.groupby('price_range').count()
```

Out[9]:

	battery_power	pc	px_width	int_memory	ram	three_g	wifi
price_range							
0.0	373	373	373	373	373	373	373
1.0	378	378	378	378	378	378	378
2.0	387	387	387	387	387	387	387
3.0	385	385	385	385	385	385	385

In [10]:
```
seleccion_df1=seleccion_df[(seleccion_df['three_g']==0.0)]
seleccion_df1.groupby('price_range').count()
```

Out[10]:

	battery_power	pc	px_width	int_memory	ram	three_g	wifi
price_range							
0.0	127	127	127	127	127	127	127
1.0	122	122	122	122	122	122	122
2.0	113	113	113	113	113	113	113
3.0	115	115	115	115	115	115	115

In [14]:
```
import matplotlib.pyplot as plt
import numpy as np


labels = ['0.0', '1.0', '2.0', '3.0']
Si = [373, 378, 387, 385]
No= [127, 122, 113, 115]

x5 = np.arange(len(labels))  # the label locations
width = 0.25  # the width of the bars

fig, ax1 = plt.subplots()
rects1 = ax1.bar(x5 - width/2, Si, width, label='Si')
rects2 = ax1.bar(x5 + width/2, No, width, label='No')

# Add some text for labels, title and custom x-axis tick labels, etc.
ax1.set_ylabel('Count')
ax1.set_title('Celulares con 3G vs celulares sin 3G')
ax1.set_xticks(x5)
ax1.set_xticklabels(labels)
ax1.legend()

ax1.bar_label(rects1, padding=0)
ax1.bar_label(rects2, padding=0)

fig.tight_layout()

plt.show()
```

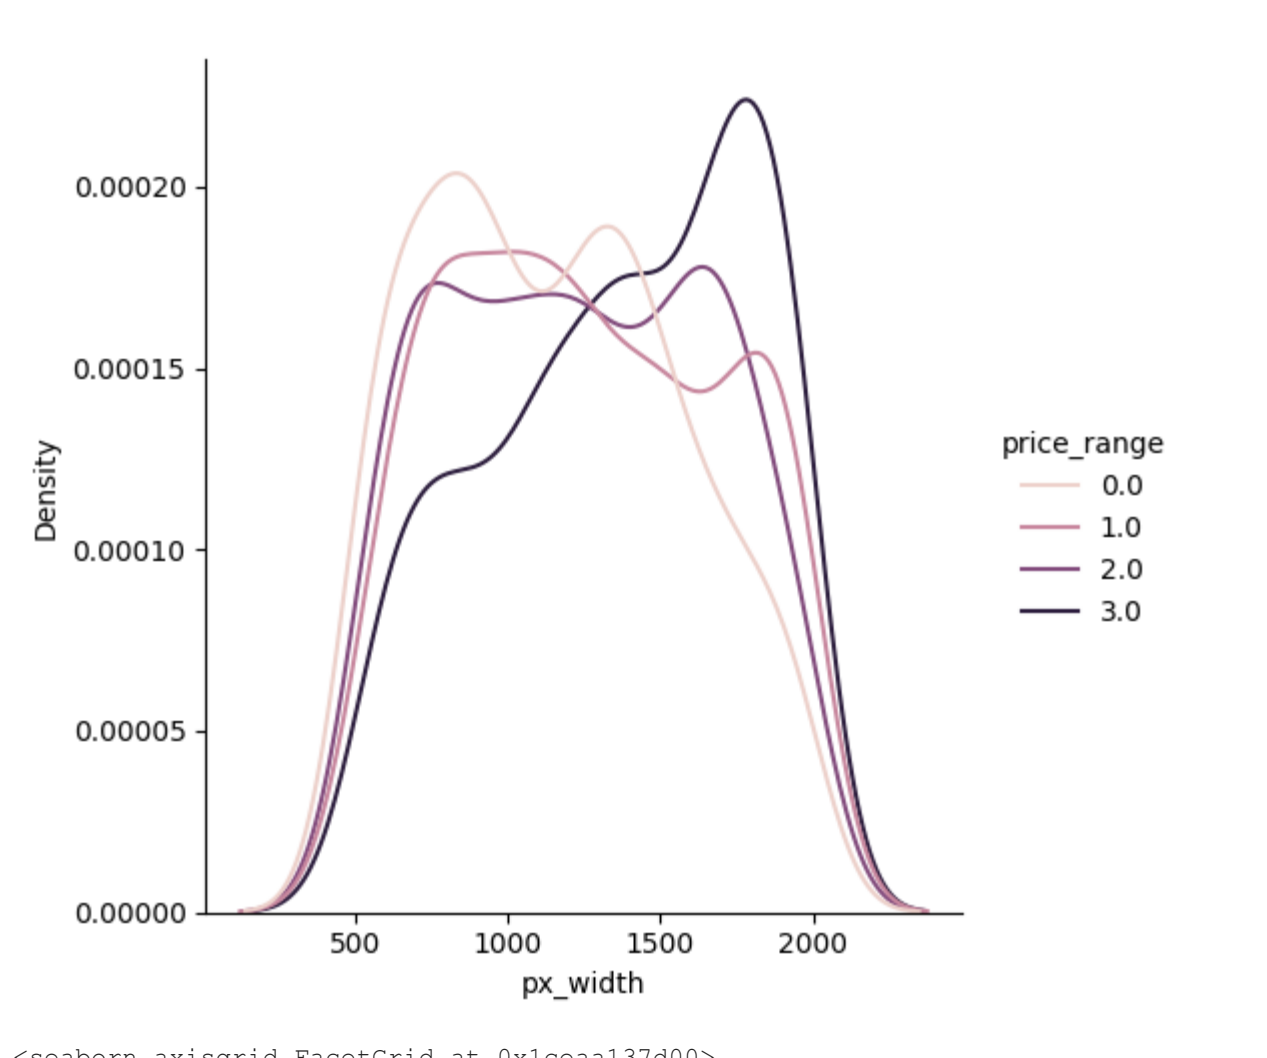

En este grafico podemos ver que, en los de precios 0.0, 1.0, 2.0 y 3.0, la cantidad de celulares con 3g son 373, 378, 387 y 385, respectivamente. Por otro lado, en esos mismos rangos de precios, tenemos que hay 127, 122, 113 y 115 celulares sin 3g, respectivamente. Por lo cual, podemos ver que hay cierta incongruencia en ambas tendencias, pues, la cantidad de celulares con 3g no siempre aumenta a medida que aumenta el rango de precio, sin embargo, la incongruencia es minima, por lo que de igual manera, se dejo este criterio.

In [12]:
```
sns.displot(data=seleccion_df, x="px_width", hue="price_range", kind="kde")
```

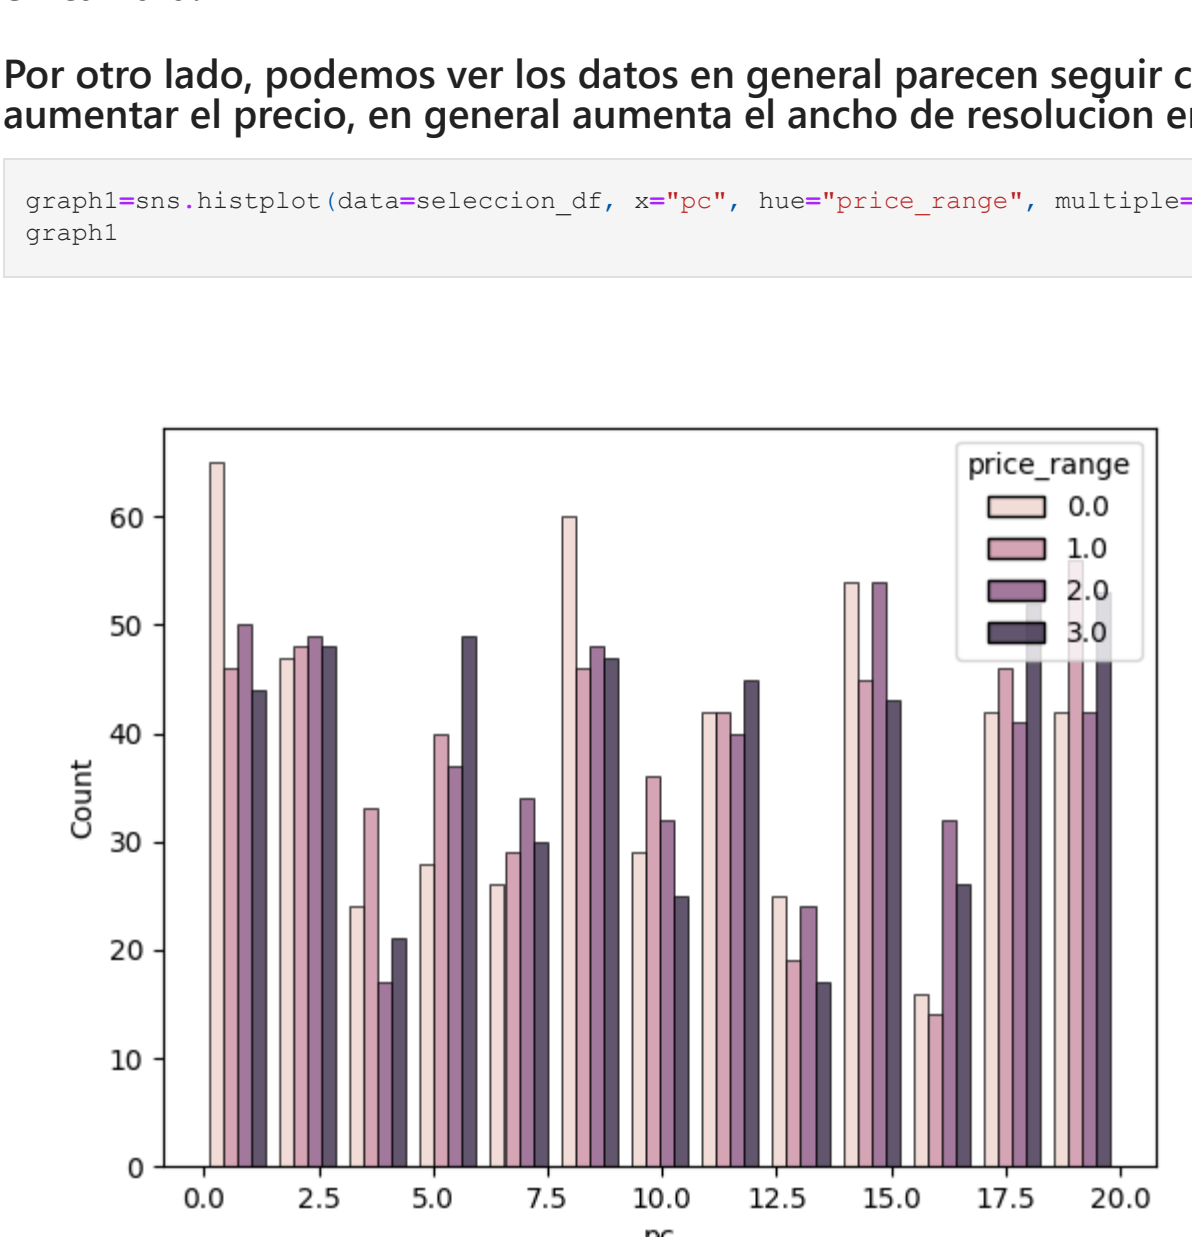

Out[12]: <seaborn.axisgrid.FacetGrid at 0x1ceaa137d00>

Como se logra ver en este grafico, en primer lugar, en el rango 0.0, hay una gran cantidad de celulares con aproximadamente 750 y 1300 pixeles de ancho de camara. En segundo lugar, tenemos que en el rango 1.0, hay una gran cantidad de celulares con 750, 1200 y 1750 pixeles de ancho de camara. Luego, en el rango 2.0, tenemos que hay una gran cantidad de celulares con aproximadamente 750 y 1600 pixeles de ancho. Finalmente, tenemos que en el rango de precio 3.0 hay una gran cantidad de celulares con aproximadamente, 1800 pixeles de ancho en camara.

Por otro lado, podemos ver los datos en general parecen seguir cierta tendencia, en la cual, al aumentar el precio, en general aumenta el ancho de resolucion en pixeles.

In [16]:
```
graph1=sns.histplot(data=seleccion_df, x="pc", hue="price_range", multiple="dodge", shrink=.8, legend=True)
graph1
```

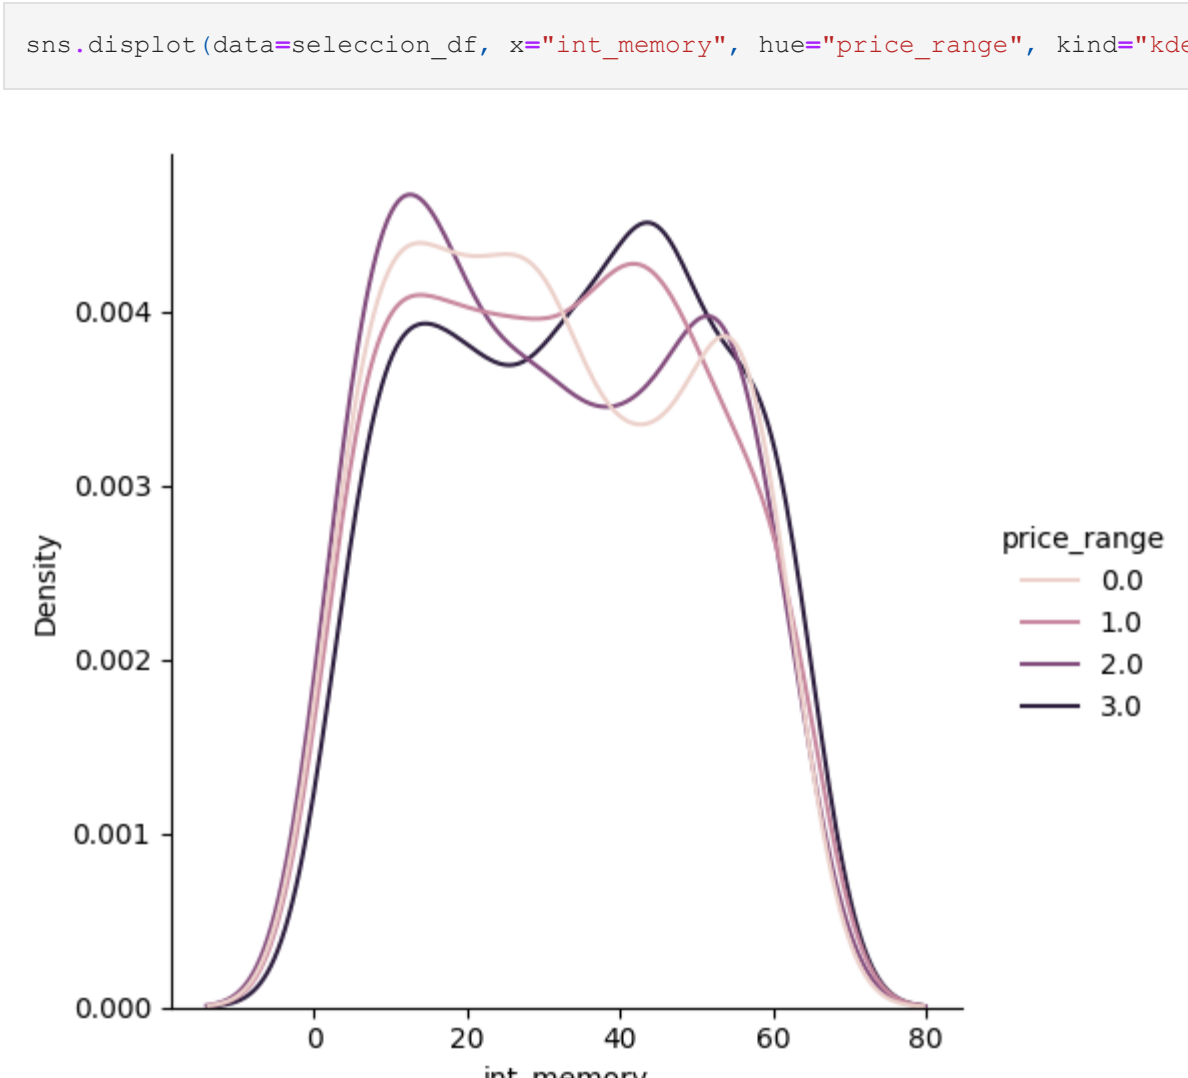

Out[16]: <AxesSubplot:xlabel='pc', ylabel='Count'>

La presente grafica, enfrenta la cantidad celulares versus la cantidad de pixeles que posee su camara pincipal, distinguiendo la su rango de precio de 0.0 la mayoria de los celulares se encuentra por debajo de encontrando sus picos por debajo de los 20 pixeles. En el rango de precio 1.0 encontramos como se mantiende, y tiende a tener una leve subida en cuanto se va aumentando su cantidad de pixeles. El rango de precio 2.0 es muy parecido al anterior no obstante tiene la tendencia subir con aun mas cantidad de pixeles. Por ultimo encontramos el rango de precio 3.0 que en su mayoria encontramos que la camara principal tiene 20 pixeles y es aqui donde se encuentra la mayoria de celulares.

In [17]:
```
sns.displot(data=seleccion_df, x="int_memory", hue="price_range", kind="kde")
```

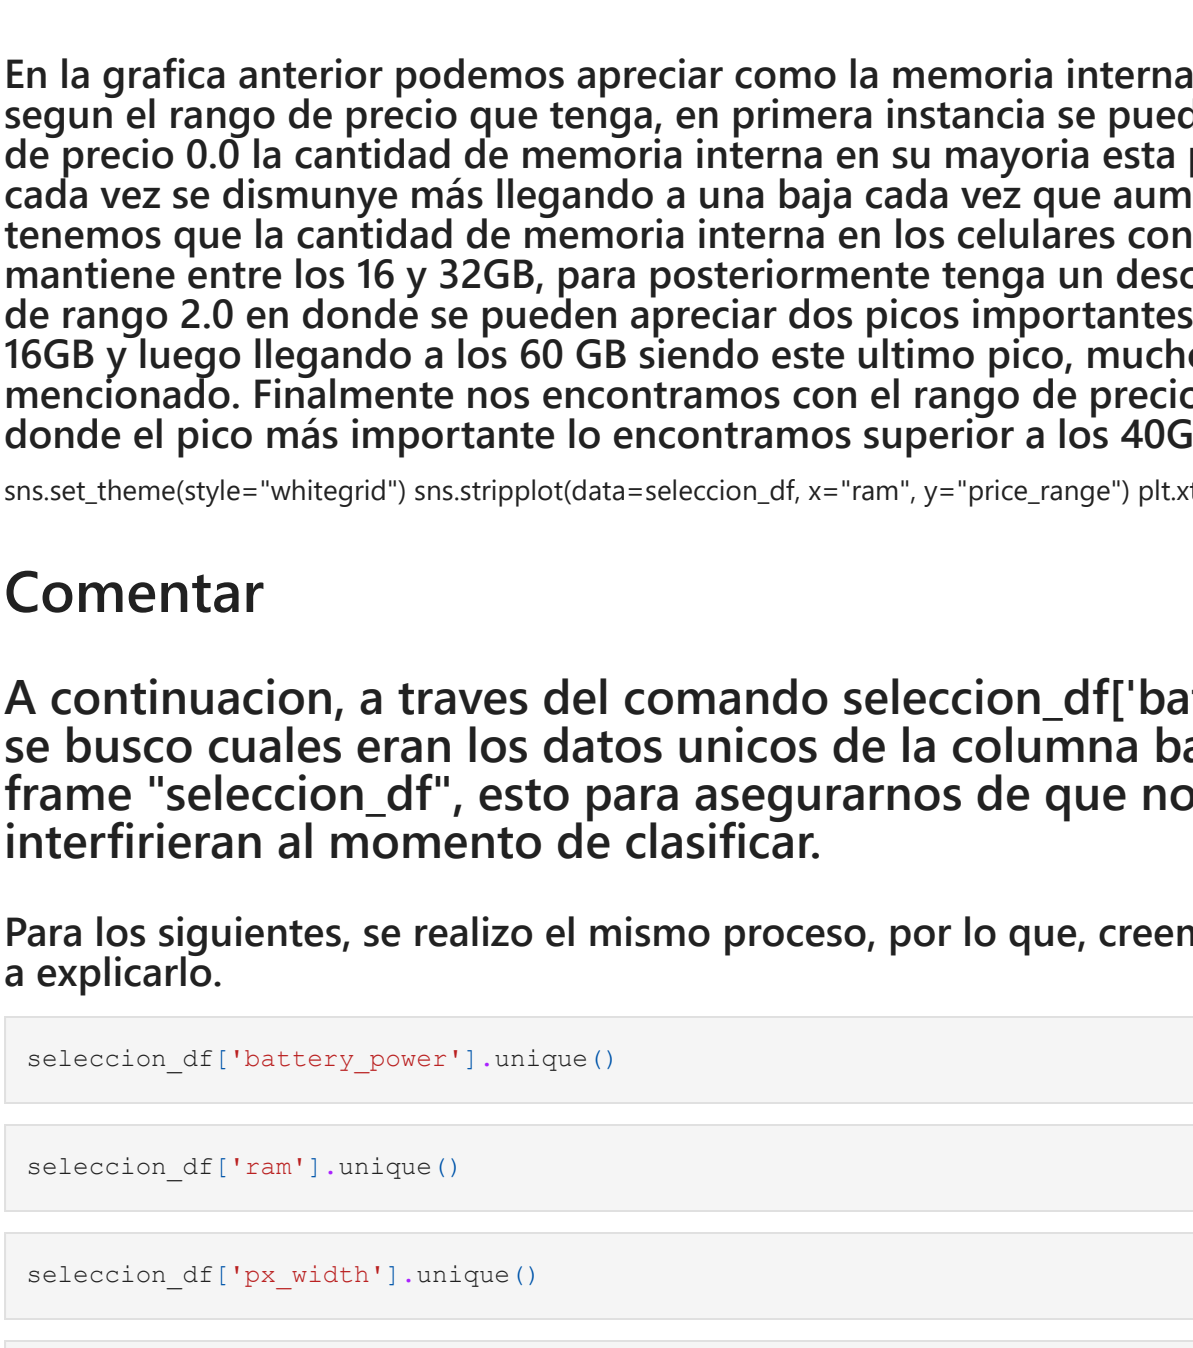

Out[17]: <seaborn.axisgrid.FacetGrid at 0x1ceac7c75e0>

En la grafica anterior podemos apreciar como la memoria interna de un celular va a variar segun el rango de precio que tenga, en primera instancia se puede observar que en el rango de precio 0.0 la cantidad de memoria interna en su mayoria esta por debajo de los 20GB y cada vez se dismunye más llegando a una baja cada vez que aumentamos la memoria. Luego tenemos que la cantidad de memoria interna en los celulares con rango de precio 1.0 se mantiene entre los 16 y 32GB, para posteriormente tenga un descenso. Llegando asi al precio de rango 2.0 en donde se pueden apreciar dos picos importantes en prier lugar en los de 16GB y luego llegando a los 60 GB siendo este ultimo pico, mucho menr que el anterior mencionado. Finalmente nos encontramos con el rango de precio más caro que es el de 3.0, donde el pico más importante lo encontramos superior a los 40GB de memoria interna.

sns.set_theme(style="whitegrid") sns.stripplot(data=seleccion_df, x="ram", y="price_range") plt.xticks(rotation=90)

Comentar

A continuacion, a traves del comando seleccion_df['battery_power'].unique() se busco cuales eran los datos unicos de la columna battery_power en el data frame "seleccion_df", esto para asegurarnos de que no hubieran strings que interfirieran al momento de clasificar.

Para los siguientes, se realizo el mismo proceso, por lo que, creemos seria redundante volver a explicarlo.

In [ ]:
```
seleccion_df['battery_power'].unique()
```

In [ ]:
```
seleccion_df['ram'].unique()
```

In [ ]:
```
seleccion_df['px_width'].unique()
```

In [ ]:
```
seleccion_df['pc'].unique()
```

In [ ]:
```
seleccion_df['int_memory'].unique()
```

In [ ]:
```
seleccion_df['three_g'].unique()
```

In [ ]:
```
seleccion_df['wifi'].unique()
```

In [ ]:
```
seleccion_df
```

Se crea un nuevo dataframe, esta vez sin tomar en cuenta el price_range.

In [ ]:
```
seleccion_dfint
```

Como buscamos clasificar cuales son los rangos de precios de cada celular segun sus especificaciones, mediante el comando "seleccion_df.iloc[:,:7]" se separaron las caracteristicas de los celulares del rango de precio.

In [ ]:
```
seleccion_df.iloc[:,:7]
```

Luego, mediante el comando "seleccion_df.iloc[:,7]", se tomo en cuenta los rangos de precios de todas las filas para poder asi, clasificar de manera posterior.

In [ ]:
```
seleccion_df.iloc[:,7]
```

Vector de clasificacion

In [ ]:
```
x= seleccion_df.iloc[:,:7]
y1= seleccion_df.iloc[:,7]
x.shape
x
```

Mediante el comando x.shape, se busco que de que tamaño habia quedado finalmente el conjunto x.

Vector de regresion

In [ ]:
```
seleccion_dfint.iloc[:,:6]
```

In [ ]:
```
seleccion_dfint.iloc[:,6]
```

Como se logra ver, en el dataframe "seleccion_dfint" en el que se encuentran todos los features de "seleccion_df" menos price_range, generamos una separacion, para asi, poder dar lugar a la regresion.

Hicimos una separacion entre memoria interna del celular y los otros atributos como power_battery, three_g, ram, pc, px_width y wifi.

In [ ]:
```
x_reg= seleccion_dfint.iloc[:,:6]
y_reg= seleccion_dfint.iloc[:,6]
x_reg.shape
```

Con el comando escrito a continuacion, se normalizaron los valores tanto del conjunto x y el conjunto x_reg, donde en el primero se tomaban power_battery, three_g, ram, pc, px_width, wifi e int_memory. Mientras que en el segundo se tomaban power_battery, three_g, ram, pc, px_width y wifi.

In [ ]:
```
## El standard busca normalizar los valores, tomando una muestra de una
## columna x, y restandole el promedio de los valores de esa columna.
## Posteriormente, el resultado de eso, sera dividido por la
## desviacion estandar de esa columna.
## Por otro lado, el fit calcula la media y desviacion estandar,
## para ser utilizada posteriormente para escalar.
## Y el transform, utiliza los datos obtenidos del fit, para asi, poder normalizar.
## Por ultimo, el fit_transform hace ambas de una vez.
x = StandardScaler().fit_transform(x)
x_reg = StandardScaler().fit_transform(x_reg)
```

PARTE 2

In [ ]:
```
X_entrenamiento, X_prueba, Y_entrenamiento, Y_prueba = train_test_split(x,y1, test_size=0.20)
```

Mediante el comando escrito anteriormente, se definen 4 variables, donde X_entrenamiento e Y_entrenamiento son los que se usaran para entrenar (en los cuales tendremos aproximadamente el 80% de cada grupo de datos), mientras que X_prueba e Y_prueba se usaran para testear(en los cuales tendremos aproximadamente el 20% de cada grupo de datos).

In [ ]:
```
Gaussian_NB= GaussianNB()
```

Se establece como "Gaussian_NB" al metodo de prediccion de Naive Bayes o GaussianNB.

Se utilizará el clasificador Naive Bayes, en especifico el Gaussian, por 3 motivos principalmente, en primera instancia este clasificador funciona de gran manera para trabajar con caracteristicas independientes entre si, como lo son las caracteristicas de los celulares. Por otro lado, tenemos el tiempo, Naive Bayes Gaussian nos permite tener una gran eficacia para tratar con una cantidad limitada de datos, y, por ultimo este es un metodo que nos permite entender de manera relativamente facil los resultados.

In [ ]:
```
Gaussian_NB.fit(X_entrenamiento, Y_entrenamiento)
```

Se ajustan el GaussianNB a los datos de entrenamiento X_entrenamiento e Y_entrenamiento.

In [ ]:
```
y_pred = Gaussian_NB.predict(X_prueba)
```

A traves del ajuste de GaussianNB, se prueba e intenta predecir los rangos de precios que tendran celulares segun diversas caracteristicas.

In [ ]:
```
print("Accuracy : %0.3f" % (accuracy_score(Y_prueba, y_pred, normalize=True)*100),'%')
```

Se compara Y_prueba con la prediccion realizada a traves del entrenamiento, a traves de esta, se logra aproximadamente 80%.

In [ ]:
```
Matrix_confusion= confusion_matrix(Y_prueba, y_pred)
print("Matrix_Confusion: ")
print(Matrix_confusion)
```

Se calcula la matriz de confusion, la cual es un modelo de clasificacion que evalua la precision lograda a traves de GNB, esto se hara mediante la comparacion de Y_prueba (conjunto de rango de precios que seran utilizados para testeo) e "Y_pred" (Conjunto de rango de precios que fueron calculados mediante el Gaussian NB con el conjunto de caracteristicas de celulares "X_prueba").

In [ ]:
```
class_names=['0.0','1.0','2.0','3.0']
plot_confusion_matrix(Gaussian_NB,X_prueba,Y_prueba, display_labels=class_names,cmap=plt.cm.Reds,normalize='tru
```

Para entender esta matriz de confusion, iremos desglosando por filas, en primer lugar, en la primera fila, tenemos un 92% de casos en que se predijo que las caracteristicas de celulares correspondian a un rango de precio 0.0 y realmente eran del rango de precio 0.0. Luego, tenemos que en un 8.4% de los casos, se predijo que eran de un rango de precio 1.0 y realmente eran de un rango de precio 0.0.

En segundo lugar, tenemos que hubo alrededor de un 11% de casos en los que se predijo que serian del rango de precio 0.0 y eran realmente del rango de precio 1.0. Luego, tenemos que hubo un 70% de casos en los que se predijo que las caracteristicas del celular correspondian al rango de precio 1.0 y realmente eran del rango de precio 1.0. Por ultimo, en un 19% de los casos, se predijo que las caracteristicas de celulares correspondian a un rango de precio 2.0 y realmente eran de un rango de precio 1.0.

En tercer lugar, tenemos que hubo alrededor de un 23% de casos en que se predijo que ciertas caracteristicas de celulares correspondian a un rango de precio 1.0 cuando realmente eran de un rango de precio 2.0. Luego, en un 66% de casos, se predijo que serian del rango de precio 2.0 y realmente eran de un rango de precio 2.0. Por ultimo, tenemos que en un 11% de casos se predijo que las caracteristicas de celulares pertenecian a un rango de precio 3.0 cuando en realidad eran de un rango de precio 2.0.

En cuarto lugar, tenemos un 8.3% de casos donde se predijo que ciertas caracteristicas de celulares eran acorde a un rango de precio 2.0 cuando realmente eran de un rango de precio 3.0, por ultimo, tenemos un 92% de casos donde se predijo que caracteristicas de celulares iban acorde a un rango de precio 3.0 y lo eran en realidad.

Para concluir, se extrae de esta matriz de confusion que los rangos de precios en los que mejor se desempeña el clasificador es en los rangos de precios 0.0 y 3.0.

In [ ]:
```
X_entrenamiento_,X_prueba_,Y_entrenamiento_,Y_prueba_ = train_test_split(x_reg,y_reg, test_size=0.30)
print(X_entrenamiento_.shape,X_prueba_.shape,Y_entrenamiento_.shape,Y_prueba_.shape)
```

Se definen los parametros X*entrenamiento*, X*prueba*, Y*entrenamiento* e Y*prueba* que se utilizaran para hacer la regresion a traves del Decision Tree Regressor. Los parametros X*entrenamiento* e Y*entrenamiento* corresponden a un 70% de los datos del data frame mientras que los parametros X*prueba* e Y*prueba* corresponden a un 30% de los datos del dataframe.

In [ ]:
```
regr_1= DecisionTreeRegressor(max_depth=70)
regr_2= DecisionTreeRegressor(max_depth=90)
regr_3= DecisionTreeRegressor(max_depth=95)
```

Creamos tres arboles de regresion con distintas profundades, las cuales fueron de un 70%, 90% y 95%.

In [ ]:
```
regr_1.fit(X_entrenamiento_, Y_entrenamiento_)
regr_2.fit(X_entrenamiento_, Y_entrenamiento_)
regr_3.fit(X_entrenamiento_, Y_entrenamiento_)
```

Ajustamos los datos de cada conjunto de entrenamientos segun las profundidades que mencionamos anteriormente.

In [ ]:
```
y_1=regr_1.predict(X_prueba_)
y_2=regr_2.predict(X_prueba_)
y_3=regr_3.predict(X_prueba_)
```

A partir de los datos aprendidos a traves de los conjuntos de entrenamiento, se intentan predecir los valores de memorias internas segun distintos parametros como pc, battery_power, etc y se guardan en las variables y_1, y_2 e y_3.

In [ ]:
```
print('max_depth = 70 score=',regr_1.score(X_prueba_,Y_prueba_))
print('max_depth = 90 score=',regr_2.score(X_prueba_,Y_prueba_))
print('max_depth = 95 score=',regr_3.score(X_prueba_,Y_prueba_))
```

Se comparan los valores de memoria interna predichos a traves de los valores de X*prueba* y se comparan con los valores reales. Se puede ver que la capacidad de prediccion es nula o hasta peor que nula.

In [ ]:
```
regr_1.feature_importances_
```

Se calcula la importancia de las caracteristicas del celular al momento de predecir la memoria interna, sin embargo, no sabemos que tan fiable es esta medida despues de que la capacidad de prediccion fue pauperrima.

In [ ]:
```
from sklearn.manifold import TSNE
Visualizacion_X= TSNE(n_components=1).fit_transform(X_prueba_)
Visualizacion_X.shape
```

El TSNE ayuda a visualizar datos con una gran cantidad de dimensiones de una manera mas simplificada, mediante el comando n_components, elegimos la cantidad de dimensiones en la que que queremos que se exprese nuestra Visualizacion_X. Por otro lado, tenemos que el fit_transform, nos ayuda a ajustar y transformar los datos de X*prueba* a los resultados o dimensiones extraidos de TSNE o t-distributed Stochastic Neighbor Embedding.

In [ ]:
```
fig,ax=plt.subplots(figsize=(5,5))
ax.plot(Visualizacion_X[0:50], Y_prueba_[0:50],'ro', label='Original data')
ax.plot(Visualizacion_X[0:50], y_1[0:50], 'g+', label='Regression 1')
## ax.plot(Visualizacion_X[0:50], y_1[0:50], 'g+', label='Regression 2')
plt.xlabel('Predicted')
plt.ylabel('Reduced 1d')
ax.legend()
```

Tenemos que figsize nos ayuda a elegir el tamaño de la ventana del grafico. Luego, se plotean 50 puntos que se ubicaran en coordenadas dadas por [Visualizacion_X[0:50], Y*prueba*[0:50]] y a los que se les llamara "Original data". De la misma manera, se plotearan otros 50 puntos que se ubicaran en las coordenadas [Visualizacion_X[0:50], Y_1[0:50]], a estos, se les llamara Regression 1.

Posteriormente, tenemos que el eje x tendra la etiqueta "Predicted", mientras que el eje y tendra la etiqueta "Reduced 1d". El comando ax.legend muestra el cartelito.

Del grafico, se concluye, que la capacidad de prediccion a traves de los datos utilizados anteriormente es pesima.

In [ ]:
```
seleccion_dfint
```

In [ ]:
```
data_features = pd.DataFrame([[0.27663488,'battery_power'],
                 [0.15127242,'pc'],
                  [0.23664646,'px_width'],
                  [0.28786069,'ram'],
                  [0.02568912, 'three_g'],
                  [0.02189644,'wifi']], columns=['FeatureValue', 'FeatureName'])
```

Creacion de dataframe para poder visualizar la importancia de cada caracteristica al momento de realizar la regresion para predecir la memoria interna

In [ ]:
```
fig_ = plt.figure(figsize=(5,5)) ## Tamaño grafico
feat__ = sns.barplot(x='FeatureName',y='FeatureValue', data=data_features) ### Ploteo grafico
plt.xlabel('Importancia de las features') ## Etiqueta EJE X
```

En el grafico, podemos ver, que al momento de predcir la capacidad de memoria interna, dependemos un 27% del poder de bateria, un 15% de los megapixeles de la camara principal, un 23% del ancho de la pantalla, un 29% del ram, un 3.5% del 3g y un 2.5% del wifi.

Sin embargo, no sabemos que tanto podemos confiar de la importancia de estas caracteristicas, pues, nuestra capacidad de prediccion fue pesima.

PARTE 3 - INFORME

¿Cómo resolvieron el tema de los valores nulos? /endtype:0.5/

R// Para solucionar el problema de los valores nulos, lo que hicimos fue eliminarlos a través de la función dropna(). Esto nos permitió trabajar con información completa en el momento de recopilar información precisa sobre las características de los cráteres y sus correspondientes diámetros. /endtype:0.5/

¿_Que normalizaste, Ran o solamente? Por qué? Muy por otra normalizar los datos?¿Que tipo de normalización usaste y por qué?/endtype: 0.5/

R// En este caso, normalizamos columnas, pues aran los datos que se relacionaban entre sí. no hubiera tenido sentido sacar el promedio de diferentes tipos de características con diferentes unidades de medida. Por ejemplo, no tiene sentido sacar el promedio de la edad y el ingreso mensual familiar a menos que ambas estén en la misma escala. Para esto, usamos utilizamos StandardScaler() de sklearn.preprocessing. Esta función estandariza las características para que tengan una media de cero y una desviación estándar de uno, lo que es útil para algoritmos de aprendizaje automático que son sensibles a la escala de las características de entrada. /endtype:0.5/

¿Qué observaste en los datos, algún patrón? ¿Algo que destacar? ¿Algo que llamara la atención? ¿Algo que te sorprendió? ¿Algo que quieras comentar particular? /endtype:0.5/

R// Utilizamos gráficos de barras, líneas, puntos y cajas, debido a que eran fáciles de entender en la mayoría y permitían obtener conclusiones sin ser humanos. En general se pudo observar que los cráteres más grandes tienden a ser más profundos, lo que tiene sentido ya que se espera que aumentando los rangos de precio, también tendrían a aumentar las medidas de cada cráter. Además, se observó que la mayoría de los cráteres tienen un precio habitual cercano con hasta solo 400 interrupciones, como puntos serie este/5

¿_Por que se separan los datos en set de entrenamiento y set de prueban?¿Que proporcion de los datos utilizaste para cada uno y por qué?/endtype:0.5/

R// Existe se separan debido a que, si usas los mismos datos para entrenar y luego analizar el rendimiento del modelo, es como hacer trampa porque el modelo ya conoce las respuestas. Por eso, dividimos los datos en dos partes: el conjunto de entrenamiento y el conjunto de prueba. /endtype:0.5/

¿Qué tan bien funcionó tu clasificador? Hablo de los resultados o la hora de predecir. Por otro lado, utilizaste un 70% de entrenamiento y un 30% de prueba en el clasificador, pues, ¿se los cambiaste? ¿Probaste con otras proporciones? ¿Cuál fue la mejor proporción para entrenar, dejar hacer a un error mas bien, o planes de otra manera, una mejor precisión.